

MAESTRÍA EN INTELIGENCIA ARTIFICIAL

MATEMÁTICAS Y PROGRAMACIÓN IA

PROPUESTA DE PROYECTO

Roberth Chachalo · Jaime Astudillo

30 de agosto de 2026

Tema

IA industrial consciente del riesgo: predicción conforme y abstención selectiva para diagnóstico de fallas bajo incertidumbre.

El proyecto no pregunta si es posible clasificar fallas de maquinaria, sino una pregunta distinta y menos explorada: *¿cuándo debería un sistema de IA industrial decidir de forma autónoma, y cuándo debería abstenerse y solicitar intervención humana?* Para responderla se implementa desde cero el marco de *predicción conforme* (*conformal prediction*, CP), una técnica de cuantificación de incertidumbre con garantías distribution-free, y se construye sobre él una política de decisión de tres vías cuyo comportamiento se evalúa en términos de costo operativo y de capacidad de reconocer situaciones nunca vistas.

Descripción funcional

Problema

En una planta industrial, las decisiones derivadas de un modelo tienen costos marcadamente asimétricos: detener una línea de producción sin motivo es caro, pero no detectar una falla inminente lo es mucho más, y confundir un modo de falla con otro envía al técnico equivocado con la herramienta equivocada. Un clasificador convencional devuelve siempre la clase más probable, sin ningún mecanismo principiado para distinguir los casos en que su predicción es confiable de aquellos en que no lo es. La probabilidad que reporta el modelo no constituye una garantía: es una salida no calibrada del propio modelo, y en presencia de desbalance severo tiende a ser optimista justamente donde menos conviene.

El sistema propuesto transforma la incertidumbre matemática en una decisión operativa de tres vías, gobernada por el tamaño del conjunto de predicción $\mathcal{C}(x)$:

Condición	Vía	Interpretación operativa
$ \mathcal{C}(x) = 1$	Automática	Evidencia suficiente; el sistema actúa solo.
$ \mathcal{C}(x) = 2$	Asistida	Diagnóstico parcial útil que orienta al técnico.
$ \mathcal{C}(x) > 2$	Humana	Sin evidencia discriminante; escalamiento.
$ \mathcal{C}(x) = 0$	Humana	Observación atípica; posible modo desconocido.

El caso $|\mathcal{C}(x)| = 2$ merece énfasis: no es un fracaso del sistema. Decirle a un técnico “es falla

térmica o por sobreesfuerzo, no otra cosa” es información accionable que descarta el resto del espacio de diagnóstico con garantía estadística.

Datos

Se utilizará el **AI4I 2020 Predictive Maintenance Dataset** del UCI Machine Learning Repository: 10 000 registros, cada uno correspondiente a un ciclo de operación de una fresadora industrial. Es un conjunto sintético, pero generado para reproducir la telemetría y los mecanismos de falla de una máquina real.

Variables predictoras: **Type** (calidad del producto, categórica en tres niveles L/M/H con proporciones 50%, 30% y 20%), **Air temperature [K]**, **Process temperature [K]**, **Rotational speed [rpm]**, **Torque [Nm]** y **Tool wear [min]**.

La variable objetivo se construirá como un problema **multiclase de cinco categorías** a partir de los indicadores binarios de modo de falla:

Clase	Modo de falla	Mecanismo físico asociado
Normal	Sin falla	—
TWF	Desgaste de herramienta	Desgaste acumulado sobre umbral
HDF	Disipación de calor	Diferencial térmico insuficiente
PWF	Potencia	Producto torque×velocidad fuera de rango
OSF	Sobreesfuerzo	Producto desgaste×torque sobre umbral

El conjunto registra aproximadamente 339 fallas (3.39%), repartidas de forma desigual entre los modos, sobre una clase mayoritaria que concentra cerca del 96.6% de los registros. Este desbalance severo es deliberado en la elección: es el régimen en que el conformal marginal falla y en que la variante Mondrian se vuelve necesaria.

Tratamiento explícito de RNF. El conjunto incluye un quinto indicador, **RNF** (*random failure*), que se asigna con probabilidad fija independientemente de los parámetros de operación de la máquina. Al no poseer firma física alguna, es estadísticamente indistinguible de la operación normal y constituye ruido irreducible: ningún modelo puede predecirlo, y usarlo como clase objetivo introduciría un techo artificial de error. Se excluye por tanto del espacio de etiquetas, y su exclusión se documenta y cuantifica como parte del análisis. Los registros con más de un modo de falla activo simultáneamente se resolverán mediante una regla de prioridad documentada, reportando su frecuencia.

Experimentos

Experimento 1 — Ablación física en métricas conformes. Se construyen dos representaciones y se comparan bajo cobertura fija:

$$\text{Modelo A} = X_{\text{original}} \quad \text{vs.} \quad \text{Modelo B} = X_{\text{original}} \cup X_{\text{físico}},$$

donde $X_{\text{físico}}$ recoge variables derivadas con sentido mecánico: potencia $P = \tau \omega$ (ligada a PWF), diferencial térmico $\Delta T = T_{\text{proceso}} - T_{\text{aire}}$ (ligado a HDF), y el producto desgaste×torque W_T (ligado a OSF). La comparación *no* se hace en exactitud sino en las métricas propias del marco conforme, según el esquema:

Representación	Cobertura	Tamaño medio $ \mathcal{C} $	Abstención
Original	$\approx 1 - \alpha$	—	—
+ características físicas	$\approx 1 - \alpha$	—	—

La hipótesis a contrastar es que ambas representaciones alcanzan la cobertura nominal, pues la garantía no depende del modelo, pero que la representación con conocimiento físico lo logra con conjuntos más pequeños, es decir, derivando menos casos a revisión humana. Una conclusión de esa forma es sustancialmente más informativa que un incremento de exactitud.

Experimento 2 — Política de decisión sensible al costo. Se define una matriz de costos $C(y, \hat{y})$ que penaliza de forma asimétrica los distintos errores, junto con costos fijos c_{asist} y c_{humano} para las vías asistida y de escalamiento. Se comparan dos políticas:

$$\pi_{\text{base}}(x) = \arg \max_y \hat{p}(y | x), \quad \pi_{\text{CP}}(x) = \begin{cases} \text{automático,} & |\mathcal{C}(x)| = 1 \\ \text{asistido,} & |\mathcal{C}(x)| = 2 \\ \text{humano,} & \text{en otro caso} \end{cases}$$

evaluadas mediante el costo esperado empírico

$$\widehat{\text{Costo}}(\pi) = \frac{1}{N} \sum_{i=1}^N C(y_i, a_i), \quad a_i = \pi(x_i).$$

Barriando α se obtiene la curva de costo esperado y con ella el nivel de confianza α^* que lo minimiza, lo cual arroja un resultado con lectura directa: *la estructura de costos del proceso determina el nivel de confianza óptimo del sistema*. Se reportará además el umbral de indiferencia a partir del cual la revisión humana deja de ser rentable. Los costos serán escenarios simulados y declarados como tales; no se afirmará que corresponden a los costos reales de ninguna empresa, y se acompañarán de un análisis de sensibilidad frente a su elección.

Qué se entregará

Un paquete de Python instalable que envuelve cualquier clasificador con interfaz compatible con `scikit-learn` y lo convierte en un predictor conforme con política de decisión sensible al costo, junto con notebooks reproducibles que documentan los experimentos y la validación empírica de las garantías teóricas.

Descripción técnica

Fundamento matemático

Sea $\{(X_i, Y_i)\}_{i=1}^n$ un conjunto de calibración disjunto del de entrenamiento y sea $\hat{f}$ un modelo ya entrenado. Se define una *función de no-conformidad* $s(x, y)$ que mide cuán poco concuerda la etiqueta y con lo que el modelo predice para x ; por ejemplo $s(x, y) = 1 - \hat{f}_y(x)$. Con las puntuaciones de calibración $s_i = s(X_i, Y_i)$ se toma el cuantil empírico

$$\hat{q} = \text{Cuantil}\left(\{s_1, \dots, s_n\}; \frac{\lceil (n+1)(1-\alpha) \rceil}{n}\right),$$

y para una observación nueva X_{n+1} el conjunto de predicción es

$$\mathcal{C}(X_{n+1}) = \{y : s(X_{n+1}, y) \leq \hat{q}\}.$$

El resultado central que se demostrará e implementará es el **teorema de cobertura marginal**: si $(X_1, Y_1), \dots, (X_{n+1}, Y_{n+1})$ son intercambiables, entonces

$$\mathbb{P}(Y_{n+1} \in \mathcal{C}(X_{n+1})) \geq 1 - \alpha.$$

La garantía no depende de que $\hat{f}$ sea un buen modelo ni de la distribución de los datos; solo requiere intercambiabilidad. Un modelo deficiente produce conjuntos grandes, no conjuntos incorrectos: la incertidumbre se traduce en tamaño, no en error. Es precisamente esa propiedad la que permite construir sobre ella una política de abstención. La demostración se apoya en un argumento de simetría sobre el rango de s_{n+1} entre las $n + 1$ puntuaciones, y se verificará empíricamente mediante simulación repetida.

Se implementarán tres variantes, cada una motivada por una necesidad concreta del problema:

- **Split conformal**, como línea base y soporte de la demostración.
- **Conformal Mondrian (condicionado por clase)**, que calcula un cuantil $\hat{q}_k$ separado por modo de falla y garantiza cobertura *por clase* y no solo en promedio. Es indispensable aquí: con un 96.6% de casos normales, una cobertura marginal del 95% puede alcanzarse ignorando por completo las clases minoritarias, que son justamente las que importan.
- **Adaptive Prediction Sets (APS)**, que acumula probabilidades ordenadas de forma decreciente hasta superar el umbral, produciendo conjuntos cuyo tamaño se adapta a la dificultad de cada observación — propiedad directamente relevante para la política de tres vías.

Pipeline

1. **Carga y exploración.** Ingesta, análisis exploratorio, cuantificación del desbalance, de los casos con modos simultáneos y de la incidencia de RNF.
2. **Ingeniería de características.** Construcción de $X_{\text{físico}} (P, \Delta T, W_T)$, codificación ordinal de **Type** y estandarización de las variables continuas.
3. **Partición en tres bloques.** Entrenamiento, *calibración* y prueba, con estratificación por clase. La separación del bloque de calibración es un requisito estructural: reutilizar datos de entrenamiento rompe la intercambiabilidad y con ella la garantía.
4. **Modelos base.** Se entrenan dos clasificadores elegidos deliberadamente en extremos opuestos de calidad, para demostrar que la cobertura se sostiene con independencia del modelo: *gradient boosting* por histogramas (**HistGradientBoostingClassifier**) como modelo fuerte, y Naive Bayes gaussiano (**GaussianNB**) como modelo deliberadamente deficiente. Este último asume independencia entre variables, supuesto que el conjunto viola de forma flagrante — torque y velocidad de rotación están acopladas, igual que las dos temperaturas —, y produce en consecuencia probabilidades notoriamente sobreconfiadas. El contraste es intencional: si ambos alcanzan la cobertura nominal y difieren únicamente en el tamaño del conjunto de predicción, queda demostrado empíricamente que la garantía no proviene del clasificador sino del procedimiento conforme.

5. **Capa conforme.** Implementación propia en NumPy de las tres variantes, expuestas mediante una clase con interfaz `fit/calibrate/predict_set`.
6. **Capa de decisión.** Matriz de costos, políticas π_{base} y π_{CP} , y cómputo del costo esperado en función de α .
7. **Validación empírica.** Verificación de que la cobertura observada alcanza el nivel nominal, mediante particiones repetidas de calibración/prueba para distintos valores de α .
8. **Ejecución de los experimentos** y análisis conjunto.

Métricas de evaluación

Un predictor conforme no se evalúa por exactitud. Los criterios son:

- **Cobertura empírica**, marginal y condicionada por clase, contrastada contra el nivel nominal $1 - \alpha$. Es la restricción a satisfacer, no el objetivo a maximizar.
- **Eficiencia**: tamaño promedio del conjunto de predicción. Sujeto a cumplir la cobertura, conjuntos más pequeños son mejores.
- **Tasa de abstención**: fracción de casos derivados a las vías asistida y humana, es decir, la carga de trabajo que el sistema traslada a personas.
- **Costo esperado** bajo la matriz de costos simulada, comparando π_{CP} contra π_{base} .
- **Tasa de abstención ante clases no vistas** (extensión), contrastada contra la tasa sobre clases conocidas.

Librerías

- **numpy** — implementación propia de toda la maquinaria conforme: cuantiles, puntuaciones de no-conformidad, construcción de conjuntos y capa de costos.
- **pandas** — carga y transformación de datos.
- **scikit-learn** — únicamente para los modelos base y las particiones. **No** se usará ninguna biblioteca de predicción conforme existente (**MAPIE**, **crepes**); estas servirán solo como contraste de validación al final, para confirmar que la implementación propia reproduce sus resultados.
- **matplotlib** — curvas de cobertura, distribuciones de tamaño de conjunto, curvas de costo frente a α y matrices de decisión.
- **pytest** — pruebas unitarias, incluyendo una prueba estadística que verifica la garantía de cobertura sobre datos sintéticos.
- **uv** — gestión de dependencias y entorno reproducible.

Arquitectura del código

Paquete instalable con separación entre la lógica matemática, el dominio y la capa de decisión:

- **scores.py** — funciones de no-conformidad.

- `conformal.py` — split conformal, Mondrian y APS.
- `features.py` — ingeniería de características físicas.
- `decision.py` — matriz de costos y políticas de decisión.
- `evaluation.py` — cobertura, eficiencia, abstención y costo.
- `experiments/` — los experimentos como scripts reproducibles.
- `notebooks/` — análisis y figuras.
- `tests/` — pruebas unitarias y de garantía estadística.

Objetivos

Objetivo general

Diseñar, implementar desde cero y evaluar un sistema de diagnóstico industrial de fallas que convierta la incertidumbre cuantificada mediante predicción conforme en una política de decisión de tres vías — automática, asistida y humana —, y determinar en qué medida el conocimiento físico del dominio y la estructura de costos del proceso modifican el punto de operación óptimo de dicha política.

Objetivos específicos

1. Estudiar y exponer el fundamento matemático de la predicción conforme: intercambiabilidad, funciones de no-conformidad, cuantiles empíricos y la demostración del teorema de cobertura marginal.
2. Implementar en NumPy, sin recurrir a bibliotecas de predicción conforme, las variantes split conformal, Mondrian y Adaptive Prediction Sets.
3. Verificar empíricamente que la cobertura observada alcanza el nivel nominal para distintos valores de α tanto con un clasificador fuerte (*gradient boosting*) como con uno deliberadamente mal calibrado (Naive Bayes gaussiano), confirmando que la garantía es independiente del clasificador y que la diferencia de calidad se manifiesta en el tamaño del conjunto de predicción y no en la cobertura.
4. Demostrar que el conformal marginal subcubre las clases minoritarias de fallas y que la variante Mondrian corrige ese fallo, cuantificando la diferencia.
5. (**Experimento 1**) Determinar si la ingeniería de características con fundamento físico reduce el tamaño promedio del conjunto de predicción y la tasa de abstención bajo cobertura fija, es decir, si el conocimiento del dominio reduce la incertidumbre del sistema y no solo su error.
6. (**Experimento 2**) Formular una matriz de costos asimétrica, comparar la política conforme de tres vías contra la política de máxima probabilidad en costo esperado, e identificar el nivel de confianza α^* que lo minimiza junto con el umbral de indiferencia de la revisión humana.